

گزارش پروژه

بررسی روش‌های اندازه‌گیری سرعت جریان آب رودخانه‌ها مبتنی بر پردازش تصویر

انجام شده توسط: شیما جعفری

هدف پروژه، طراحی یک مدل تخمین سرعت جریان آب با استفاده از ویدیوهای سطح آب و بررسی روش‌های مختلف پردازش تصویر، یادگیری ماشین و یادگیری عمیق بود.

طی این پروژه با توجه به تحقیقات انجام شده، مقاله‌ای مبتنی بر optical flow برای انجام این کار انتخاب شد اما با پیاده‌سازی این روش با توجه به چالش‌هایی اعم از کمبود دیتا و ... به سراغ تست چند روش دیگر رفتیم. به همین دلیل طی این پروژه از چند مدل و روش استخراج ویژگی استفاده شد که در ادامه به آنها خواهیم پرداخت.

1. مشخصات سیستم

CPU: Intel Core i7-8750H – 6 Core – 12 Thread

RAM: 8 GB

GPU: NVIDIA GTX 1050 4GB

Operating System: Windows 11

Development Environment: PyCharm

Programming Language: Python 3.12

Libraries:

- OpenCV
- NumPy
- Pandas
- Scikit-Learn
- PyTorch
- TorchVision
- Joblib
- Matplotlib

2. دیتاست

دیتاست شامل:

- 24 ویدیو از جریان آب رودخانه
- فرمت MP4 و AVI
- فایل Label شامل سرعت واقعی جریان آب

پس از بررسی اولیه مشخص شد:

- دو نمونه دارای مقدار سرعت نامعتبر بودند.
- 22 نمونه دارای برچسب معتبر برای آموزش و ارزیابی باقی ماندند.

چالش‌های دیتاست:

- وجود موج و آشفتگی سطح آب
- تفاوت مدت زمان ویدیوها
- تفاوت زاویه دوربین
- تفاوت نور محیط
- محدود بودن تعداد نمونه‌ها
- وجود بازتاب نور

3. روند انجام پروژه

پروژه به صورت مرحله‌ای توسعه داده شد تا بتوان عملکرد روش‌های مختلف را به صورت مستقل ارزیابی و مقایسه کرد.

Phase 1 – Dataset Analysis

هدف: بررسی کیفیت دیتاست و استخراج اطلاعات اولیه ویدیوها.

اقدامات انجام شده

- خواندن فایل Label
- بررسی وجود فایل‌ها
- استخراج FPS
- استخراج مدت زمان
- استخراج رزولوشن
- شناسایی نمونه‌های نامعتبر

خروجی: فهرست کامل مشخصات ویدیوها و حذف نمونه‌های دارای Label نامعتبر.

Phase 2 – Video Preprocessing

هدف: آماده‌سازی ویدیوها برای استخراج ویژگی.

اقدامات

- استخراج فریم‌ها
- تغییر اندازه تصاویر
- تبدیل به Grayscale
- کاهش نویز با Gaussian Blur
- بهبود کنتراست

دلیل انجام: کاهش نویز و استانداردسازی داده‌ها باعث افزایش پایداری الگوریتم‌های استخراج ویژگی می‌شود.

Phase 3 – Optical Flow Feature Extraction ▪

دلیل انتخاب Optical Flow

مطالعه مقالات مرتبط با:

- Surface Velocity Estimation
- Large Scale Particle Image Velocimetry (LSPIV)
- River Monitoring

نشان داد که Optical Flow یکی از رایج‌ترین روش‌های مورد استفاده برای تخمین سرعت سطح آب است.

مزایا: - عدم نیاز به مارکر - عدم نیاز به جسم شناور - محاسبه حرکت کل تصویر

الگوریتم انتخاب شده: Farneback Dense Optical Flow

دلیل انتخاب Farneback :

- سرعت بالا
- عدم نیاز به GPU
- پایداری مناسب
- پیاده‌سازی آماده در OpenCV

ویژگی‌های استخراج شده

- | | |
|----------------------|----------------------|
| • Mean Magnitude | • Max Magnitude |
| • Median Magnitude | • Percentiles |
| • Standard Deviation | • Mean Direction |
| • Min Magnitude | • Direction Variance |

نتیجه: وجود ارتباط بین ویژگی‌های حرکتی و سرعت واقعی تأیید شد.

Phase 4 – Machine Learning Baseline ▪

هدف: ایجاد اولین مدل پیش‌بینی.

مدل‌های بررسی شده

- Random Forest
- Extra Trees
- Gradient Boosting
- SVR
- Ridge Regression

دلیل انتخاب: این مدل‌ها برای دیتاست‌های کوچک عملکرد مناسبی دارند.

روش ارزیابی: Leave-One-Out Cross Validation

دلیل انتخاب **LOO**: با توجه به وجود تنها 22 نمونه، استفاده از Train/Test Split باعث از دست رفتن بخش زیادی از اطلاعات می‌شد.

▪ Phase 5 – Deep Learning Baseline

هدف: بررسی امکان استفاده از شبکه عصبی.

مدل: MLP

نتیجه: به دلیل کم بودن تعداد نمونه‌ها مدل دچار Overfitting شد.

▪ Phase 6 – Improved Motion Features

هدف: افزایش کیفیت توصیف حرکت.

ویژگی‌های جدید

- Mean Flow X
- Mean Flow Y
- Absolute Motion
- Motion Density
- Temporal Statistics

نتیجه: بهبود عملکرد نسبت به Phase 4.

▪ Phase 7 – KLT Feature Tracking

هدف: بررسی امکان ردیابی نقاط شاخص روی سطح آب.

الگوریتم

- Shi-Tomasi
- Lucas-Kanade

فرضیه: حرکت نقاط شاخص می‌تواند نماینده سرعت جریان باشد.

نتیجه: عملکرد ضعیف‌تر از Optical Flow

دلیل: سطح آب ساختار صلب ندارد (شکل یا نقاط خاص ندارد) و نقاط پایدار کمی برای ردیابی وجود دارد.

▪ Phase 8 – KLT Based Regression

مدل‌های یادگیری ماشین روی ویژگی‌های KLT آموزش داده شدند.
نتیجه نشان داد که KLT به تنهایی مناسب این مسئله نیست.

Phase 9 – Advanced Motion Features ▪

هدف: استخراج ویژگی‌های سطح بالاتر.

ویژگی‌های طراحی شده

- Motion Energy = میزان انرژی کلی حرکت.
- Motion Entropy = میزان پیچیدگی حرکت.
- Active Motion Ratio = درصد نواحی فعال.
- Direction Consistency = میزان هماهنگی جهت حرکت.

نتیجه: بهبود دقت نسبت به ویژگی‌های ساده Optical Flow

Phase 10 – Advanced Motion training ▪

آموزش مدل‌ها روی ویژگی‌های جدید و مقایسه عملکرد آن‌ها.

Phase 11 – Hybrid Feature Fusion ▪

هدف: ترکیب اطلاعات حاصل از مراحل مختلف.

ویژگی‌های ترکیب شده

- Optical Flow Features
- Advanced Motion Features

نتیجه: بهبود قابل توجه عملکرد مدل.

Phase 12 – Final Feature Optimization ▪

بهینه‌سازی Feature Selection و آماده‌سازی زیرساخت برای ورود ویژگی‌های Deep Learning.

Phase 13 – Deep Feature Extraction ▪

دلیل استفاده از Deep Learning: بررسی این موضوع که آیا اطلاعاتی فراتر از حرکت در تصویر وجود دارد یا خیر.

مدل انتخاب شده: ResNet18

دلیل انتخاب: سرعت مناسب - حجم کم - عملکرد خوب - مناسب برای Transfer Learning

روش: استخراج فریم‌های منتخب - عبور از ResNet18 - استخراج بردار ویژگی 512 بعدی - تجمیع ویژگی‌ها در سطح ویدیو

Phase 14 – Hybrid Motion + Deep Features ▪

مهم ترین فاز پروژه

ویژگی های زیر با هم ترکیب شدند:

- Optical Flow
- Advanced Motion Features
- Deep Features

هدف: استفاده همزمان از اطلاعات حرکتی و بصری.

مدل برتر: Extra Trees Regressor

بهترین نتیجه پروژه: $MAE = 0.356$

Phase 15 – Deep Learning Regression ▪

مدل MLP روی Hybrid Features آموزش داده شد.

نتیجه: عملکرد ضعیف تر از Extra Trees

Phase 16 – Tiny CNN , CNN-LSTM ▪

هدف: بررسی مدل های Deep Learning روی فیچرهای جدید

مدل ها: Tiny CNN و CNN-LSTM

نتیجه: دچار Overfitting شدند.

دلیل: 22 نمونه برای آموزش شبکه های عمیق کافی نیست.

Phase 17 – Tuned Ensemble Models ▪

مدل های Ensemble و ترکیب چند مدل مختلف بررسی شدند.

نتیجه: هیچ مدل Ensemble نتوانست عملکرد بهتری از Hybrid Extra Trees ارائه دهد.

4. دلیل انتخاب مدل نهایی

Hybrid Feature Fusion + ExtraTrees Regressor

دلایل انتخاب:

- مناسب برای دیتاست کوچک
- کمترین MAE
- عدم نیاز به آموزش سنگین
- پایداری بالا
- مقاومت در برابر نویز

5. معیارهای ارزیابی

MAE: معیار اصلی پروژه

RMSE: بررسی خطاهای بزرگ

R^2 : اندازه‌گیری توان توضیح مدل

MAPE: بررسی خطای نسبی

6. نتایج نهایی

در این پروژه چند روش شامل Optical Flow ساده، KLT Tracking، ویژگی‌های پیشرفته حرکتی و ترکیب ویژگی‌ها بررسی شد. بهترین نتیجه با ترکیب ویژگی‌های Phase 6 و Phase 9 به دست آمد.

MAE: 0.4072
RMSE: 0.9616
R2: 0.3678
MAPE: 52.0011

نتایج نسبت به مدل اولیه حدود 27 درصد بهبود داشتند.

7. چالش‌های پروژه

- کم بودن تعداد نمونه‌ها
- نبود مقیاس فیزیکی
- تفاوت شرایط نوری
- تفاوت زاویه دوربین
- بازتاب نور
- ماهیت غیرصلب سطح آب
- محدودیت سخت‌افزاری

8. فرضیات پروژه

- دوربین ثابت است
- فریم‌های انتخابی نماینده کل ویدیو هستند.

9. نقاط قوت روش نهایی

- استفاده همزمان از اطلاعات حرکتی و بصری
- عملکرد مناسب روی داده کم
- عدم نیاز به تجهیزات فیزیکی
- قابلیت تعمیم مناسب
- زمان آموزش کم

10. نقاط ضعف روش نهایی

- محدودیت ناشی از کم بودن دیتاست
- عدم استفاده از مقیاس فیزیکی
- وابستگی به کیفیت ویدیو
- حساسیت به زاویه تصویربرداری

11. بررسی زمان پردازش

زمان پردازش و آموزش هر بخش در فایل `outputs/results/processing_time_log.txt` ذخیره شده است.

همچنین زمان پیش بینی میانگین برای همه ویدیو ها در مدل منتخب نهایی نیز در فایل

`outputs/results/phase14_prediction_time.txt` ذخیره شده است

نتیجه هر فاز در آدرس زیر در مخزن گیت قابل مشاهده است.

```
river_speed_project >> outputs >> results
```